

MAESTRÍA EN EXPLOTACIÓN DE DATOS Y GESTIÓN DEL CONOCIMIENTO

Plan de Trabajo Final

Evaluación del impacto de la evolución
de arquitecturas de NLP en la clasificación
de texto a escala industrial:
Un análisis comparativo sobre el
Meli Challenge 2019

Maribel Fraire

Director: Mariano Crosetti
Codirectora: Fernanda Mendez

Versión preliminar [1]
10 de marzo de 2026

Resumen

La clasificación automática de texto es una tarea central del Procesamiento de Lenguaje Natural (NLP) que se enmarca dentro del aprendizaje supervisado. En este paradigma, el algoritmo aprende a partir de un conjunto de instancias etiquetadas, ajustando iterativamente los parámetros del modelo mediante la minimización de una función de pérdida, con el objetivo de generalizar y predecir la categoría correcta para nuevas instancias no vistas durante el entrenamiento. Automatizar este tipo de tarea representa un desafío significativo en la industria, dado que transformar datos no estructurados —como los títulos de productos de un e-commerce— en categorías estructuradas es determinante para el funcionamiento de los sistemas de búsqueda y la generación de métricas que permitan la toma de decisiones.

En el contexto de la competencia de Kaggle denominada Meli Challenge 2019, la tarea consiste en clasificar título o descripciones de productos que los usuarios del e-commerce han ingresado manualmente en categorías de productos específicas, donde cada título de producto representa una instancia y cada categoría representa una clase posible. Este caso, además, presenta el desafío de que los títulos pueden estar en español o portugués pero el output, es decir, la categoría es en inglés. Como resultado de la aplicación de estos modelos se puede, partiendo de un título en lenguaje natural como ‘Samsung Galaxy S24 Ultra 256gb 12gb RAM Violeta’ etiquetarlo en una categoría como ‘Smartphone’ o 22 y al final del día generar métricas de negocio como número de ventas o proyecciones.

En este trabajo se propone evaluar el rendimiento de distintos enfoques de clasificación de texto aplicados al dataset del Meli Challenge 2019 (Kaggle): embeddings contextuales utilizando OpenAI BETO (versión en español de BERT, fine-tuned sobre el dataset completo), embeddings estáticos como FastText combinados con una red neuronal, y la replicación de la solución ganadora de la competencia basada en LSTM/GRU con embeddings FastText pre-entrenados. La comparación se realizará mediante métricas estándar (accuracy, F1-score) y permitirá identificar los factores que explican las diferencias de rendimiento entre enfoques de distinta generación y escala.

La metodología propuesta incluye el preprocesamiento del dataset (limpieza, normalización), la implementación de pipelines completos de clasificación, el análisis comparativo de resultados y la discusión de las limitaciones de reproducibilidad de soluciones basadas en dependencias tecnológicas obsoletas. Los resultados contribuyen a comprender el alcance práctico de cada paradigma (embeddings estáticos, modelos Transformer, LLM) en un problema real de NLP en español.

Palabras claves

Clasificación de texto, Deep Learning, embeddings, Large Language Models (LLM), Machine Learning, Procesamiento de Lenguaje Natural (NLP), Transformers.

1. Motivación e importancia del tema de estudio

En el núcleo del Procesamiento de Lenguaje Natural (NLP) se encuentra un problema fundamental: cómo representar el significado del lenguaje de forma que una computadora pueda razonarlo. Jurafsky y Martin (2024) ilustran esta complejidad señalando que una misma palabra puede tener múltiples sentidos según el contexto —el sustantivo *mouse* refiere tanto al roedor como al dispositivo de control del cursor— y que un modelo útil del significado debe permitir realizar inferencias para resolver tareas como respuesta a preguntas o clasificación (Jurafsky & Martin, 2024, Cap. 6). Esta ambigüedad es el problema operacional central en dominios como el comercio electrónico: el título "funda negra 13 pulgadas" puede corresponder a fundas para celulares, laptops o accesorios de moda, y el modelo debe capturar el significado contextual para resolverlo correctamente. Manning y Schütze (1999) señalan que abordar este problema requiere integrar conocimiento lingüístico con modelos estadísticos de lenguaje, lo que convierte al NLP en un área de formación especialmente exigente y de alto valor para la ciencia de datos.

La motivación central de este trabajo es adquirir dominio sobre los conceptos y herramientas que definen el estado del arte en NLP. En particular, tres paradigmas concentran el interés académico y la demanda industrial actual. Las **redes neuronales recurrentes** (RNN, LSTM, GRU) fueron el primer enfoque capaz de capturar dependencias secuenciales en el texto, demostrando que la arquitectura del modelo importa tanto como los datos (Hochreiter & Schmidhuber, 1997; Cho et al., 2014). La arquitectura **Transformer**, propuesta por Vaswani et al. (2017), reemplazó a las RNN como referencia al introducir el mecanismo de autoatención, que permite procesar secuencias completas en paralelo y capturar relaciones de largo alcance sin degradación del gradiente. Sobre esta base, los **grandes modelos de lenguaje** (LLM) como BERT y GPT, pre-entrenados sobre corpus masivos y adaptables a tareas específicas mediante fine-tuning, constituyen hoy el paradigma dominante en NLP (Devlin et al., 2019; Zhao et al., 2023). Aprender a trabajar con estos tres paradigmas en un problema real —no en un ejercicio sintético— es el objetivo formativo que orienta este trabajo.

Las áreas de aplicación que justifican este aprendizaje son amplias y de creciente relevancia. En automatización y eficiencia operativa, los sistemas de NLP permiten procesar grandes volúmenes de datos no estructurados —correos, tickets, descripciones de productos, contratos— que de otro modo requerirían revisión manual (Goodfellow, Bengio & Courville, 2016). En análisis de sentimientos y monitoreo de tendencias, modelos basados en Transformer son capaces de detectar opiniones y señales en redes sociales y reseñas a escala industrial. En accesibilidad y traducción, los LLM han transformado la calidad de los sistemas de traducción automática y los asistentes de voz, democratizando el acceso a información en múltiples idiomas (Vaswani et al., 2017). En el sector salud, legal y financiero, la clasificación automática de documentos es una herramienta crítica para la gestión del conocimiento institucional.

El Meli Challenge 2019 constituye el marco experimental de este trabajo: una competencia real de Kaggle organizada por Mercado Libre que plantea la clasificación de títulos de productos en más de 1.500 categorías (Mercado Libre, 2019). Este problema condensa los desafíos centrales del NLP aplicado —variabilidad léxica, multilingüismo, escala de datos, desbalance de clases— y permite implementar y comparar los tres paradigmas mencionados sobre el mismo dataset, con las mismas métricas y en condiciones

reproducibles. Los beneficios esperados son tanto formativos —comprensión profunda de los modelos y sus trade-offs— como contribución a la comunidad hispanohablante de ciencia de datos, que dispone de menos recursos comparativos en español que en inglés (Cañete et al., 2020).

2. Requerimientos y desafíos

La clasificación automática de texto ha sido abordada desde múltiples perspectivas en la literatura, con una evolución clara de paradigmas. Hasta 2017, las **redes neuronales recurrentes (RNN)** constituían el estado del arte en modelado de secuencias, tal como documenta la introducción del trabajo de Vaswani et al. (2017), que describe los modelos recurrentes como la referencia establecida en transducción de secuencias y modelado del lenguaje antes de proponer el Transformer.

En el paradigma de las redes recurrentes, Hochreiter y Schmidhuber (1997) introdujeron las redes **LSTM** para resolver el problema del gradiente que se desvanece en redes recurrentes estándar: como señalan en la introducción de su trabajo, los algoritmos de retropropagación en el tiempo hacen que las señales de error que fluyen hacia atrás tiendan a desvanecerse exponencialmente, lo que hace que el aprendizaje de dependencias a largo plazo tome un tiempo costoso o no funcione en absoluto. Cho et al. (2014) extendieron este paradigma con la arquitectura **RNN encoder-decoder** e introdujeron las Gated Recurrent Units (**GRUs**), una arquitectura que incorpora una update gate y una reset gate: la update gate controla cuánto del estado anterior se conserva en el estado actual, mientras que la reset gate determina cuánto del estado anterior se descarta al calcular el nuevo estado candidato. A diferencia de las LSTM, las GRUs combinan las compuertas de olvido y entrada en una única update gate y fusionan el estado de celda con el estado oculto, resultando en una arquitectura más liviana que mantiene capacidad comparable para capturar dependencias secuenciales. La solución ganadora del Meli Challenge 2019 es representativa de este enfoque: combina embeddings FastText pre-entrenados con capas LSTM y GRU, alcanzando una accuracy de 0.917 sobre el dataset completo.

A partir de 2018, la arquitectura **Transformer** (Vaswani et al., 2017) y el paradigma de **pre-entrenamiento** y **fine-tuning** transformaron el campo. Como señalan Devlin et al. (2019) en la introducción de su trabajo, el **pre-entrenamiento** de modelos de lenguaje ha demostrado ser efectivo para mejorar numerosas tareas de NLP, y los embeddings pre-entrenados son una parte integral de los sistemas modernos, **ofreciendo** mejoras significativas frente a representaciones aprendidas desde cero. El framework BERT propone dos etapas: durante el pre-entrenamiento, el modelo se entrena sobre datos no etiquetados mediante distintas tareas; durante el fine-tuning, los parámetros pre-entrenados se inicializan y ajustan con datos etiquetados de la tarea específica, siendo una característica distintiva de BERT su arquitectura unificada aplicable a diferentes tareas simplemente conectando las entradas y salidas correspondientes (Devlin et al., 2019). Este paradigma es el que se aplica en este trabajo: tanto BETO —versión de BERT pre-entrenada en español (Cañete et al., 2020)— como los embeddings de OpenAI basados en GPT se utilizan como modelos pre-entrenados que se adaptan al problema de clasificación de productos del Meli Challenge, aprovechando el conocimiento lingüístico adquirido durante el pre-entrenamiento para resolver una tarea supervisada con datos etiquetados del dominio específico.

Este trabajo representa un aporte en cuanto a la implementación y documentación de pipelines completos y reproducibles para cada enfoque, incluyendo decisiones de preprocesamiento, hiperparámetros y recursos, especialmente frente al desafío de reproducir soluciones con dependencias tecnológicas obsoletas como la del modelo usado en la competencia en 2019 (Pineau et al., 2021). A su vez, realiza una comparación sistemática

sobre el mismo dataset y con las mismas métricas, permitiendo una evaluación comparativa y equitativa de distintos enfoques de resolución de problemas dentro del NLP.

3. Problemas no resueltos

La clasificación de texto multiclase constituye uno de los problemas centrales del NLP y presenta desafíos que van más allá de la selección del modelo. Jurafsky y Martin (2024) señalan que la clasificación de texto es esencial para numerosas tareas del procesamiento del lenguaje, desde la detección de spam en correos electrónicos hasta el análisis de sentimientos en reseñas de productos, y que el objetivo es tomar una observación, extraer características útiles y asignarla a una de un conjunto de clases discretas.

Una de las decisiones más determinantes en cualquier pipeline de clasificación de texto es la estrategia de tokenización. Jurafsky y Martin (2024) documentan en el Capítulo 2 que la **tokenización** a nivel de palabra presenta el problema de palabras fuera de vocabulario (**OOV**), que afecta especialmente a dominios con alta variabilidad léxica, mientras que la tokenización por subpalabras —mediante algoritmos como Byte-Pair Encoding (BPE)— controla el tamaño del vocabulario y mejora el manejo de términos no vistos durante el entrenamiento. Esta **tensión entre granularidad y cobertura léxica** es especialmente relevante en el dominio de e-commerce, donde los recursos léxicos existentes son insuficientes: Kozareva (2015) señala que recursos como WordNet proveen a lo sumo sinónimos e hiperónimos para nombres de categorías, pero no contienen nombres de productos, marcas ni el significado de abreviaturas técnicas, lo que obliga a construir representaciones léxicas directamente desde los datos del dominio.

El problema concreto que este trabajo aborda es la clasificación automática de títulos de productos en el catálogo de Mercado Libre. El dataset del Meli Challenge 2019 contiene aproximadamente 20 millones de registros en español y portugués, distribuidos en 1.588 categorías con distribución **desbalanceada** (Mercado Libre, 2019). Esta escala y complejidad —múltiples idiomas, alta variabilidad léxica, más de 1.500 clases con representación desigual— lo convierte en un problema de clasificación multiclase exigente. He y Garcia (2009) documentan que el desbalance entre clases es uno de los principales desafíos en aprendizaje automático, ya que los modelos tienden a favorecer las clases mayoritarias, degradando el rendimiento sobre las categorías menos frecuentes.

La importancia del problema es directamente operacional: en plataformas de e-commerce de escala masiva, la categorización incorrecta de productos afecta la experiencia de búsqueda, la generación de métricas de negocio y la toma de decisiones estratégicas (Kozareva, 2015). Un sistema que no clasifique correctamente degrada la relevancia de los resultados de búsqueda y puede derivar en pérdida de ventas y menor satisfacción del usuario.

Otro problema significativo es la brecha entre el rendimiento teórico de los modelos de última generación y su **viabilidad económica** en producción. Si bien es esperable que modelos como GPT, accedidos vía API, ofrezcan buen rendimiento en clasificación de texto por la calidad de sus representaciones semánticas, clasificar 20 millones de registros mediante llamadas a una API de pago puede no superar el análisis costo-beneficio en un contexto industrial real. Esta limitación práctica motiva la comparación con alternativas de menor costo computacional como BETO con fine-tuning o FastText con redes neuronales, que operan sobre infraestructura propia.

También se presenta el desafío, poco documentado, de la degradación de la reproducibilidad de soluciones de NLP basadas en dependencias tecnológicas con ciclo de vida corto. La solución ganadora del Meli Challenge 2019 fue implementada con tecnologías que han llegado al fin de su vida útil y que no son compatibles con hardware moderno, lo que plantea una pregunta relevante para cualquier organización que intente mantener modelos entrenados en períodos anteriores: ¿qué tanto del rendimiento reportado es reproducible hoy, y a qué costo? (Pineau et al., 2021).

4. Solución propuesta

La solución propuesta consiste en el diseño e implementación de un análisis comparativo de modelos de clasificación de texto aplicados al dataset del Meli Challenge 2019. El benchmark contempla cuatro modelos propios y la replicación (con workarounds documentados) de la solución ganadora de la competencia original.

Los modelos a implementar cubren los tres paradigmas descritos en el marco teórico. En el enfoque de redes neuronales y aprendizaje profundo, se implementará una arquitectura basada en embeddings FastText combinados con una red neuronal densa, representando el paradigma de embeddings de subpalabras con aprendizaje profundo, y se replicará la solución ganadora del Meli Challenge 2019 basada en capas LSTM y GRU. En el enfoque de Transformers sin fine-tuning, se utilizarán embeddings de OpenAI (text-embedding-3-small) como representaciones densas del texto, obtenidos tanto mediante llamadas síncronas como mediante la Batch API para mayor escalabilidad, y clasificados con KNN y Random Forest. En el enfoque de Transformers con fine-tuning, se implementará BETO —versión de BERT pre-entrenada en español— adaptado al problema de clasificación de categorías de productos mediante fine-tuning sobre el dataset completo.

Este trabajo aporta evidencia empírica y documentada sobre el comportamiento de distintos enfoques para resolver un problema de clasificación de texto en NLP, un área donde la comparación sistemática entre paradigmas sobre un mismo dataset real es escasa, especialmente en español. Los ensayos implementados —con el mismo preprocesamiento y las mismas métricas de evaluación— permitirán contrastar cómo performan modelos de distintas generaciones frente a un problema concreto de alta complejidad: más de 1.500 categorías, variabilidad léxica y escala industrial. Los resultados obtenidos, junto con la documentación detallada de cada pipeline, hiperparámetros y dependencias de software, constituirán un aporte verificable y reproducible al campo, útil tanto para investigadores como para equipos de ciencia de datos que enfrenten problemas similares de clasificación en lenguaje natural.

La solución propuesta está sujeta a limitaciones técnicas y de recursos. La replicación de la solución ganadora del 2019 no será exacta: el reemplazo de CuDNNLSTM/CuDNNGRU por LSTM/GRU estándar —necesario por incompatibilidad de TensorFlow 1.14 con hardware moderno— altera la arquitectura original y potencialmente el rendimiento. No obstante, la GPU RTX 3060 disponible permite compensar parcialmente esta limitación al proveer capacidad de cómputo suficiente para ejecutar las arquitecturas adaptadas en tiempos razonables. Los experimentos con embeddings de OpenAI estarán limitados por el costo de la API, lo que restringirá el tamaño de las muestras utilizadas. Estas limitaciones abren líneas de trabajo futuro: la evaluación de modelos de lenguaje de código abierto como Mistral o LLaMA representaría una alternativa sin costo por llamada, potencialmente más viable para clasificar datasets de escala industrial; el uso de técnicas de fine-tuning eficiente como LoRA o QLoRA permitiría adaptar modelos de gran capacidad con recursos computacionales reducidos; y la extensión del análisis al subconjunto en portugués del dataset completaría la cobertura multilingüe del problema original.

5. Grado de innovación de la propuesta tecnológica

El grado de innovación de esta propuesta reside no en la introducción de un nuevo algoritmo, sino en la integración comparativa de enfoques de distintas generaciones sobre un dataset de escala real en español, con documentación sistemática de las condiciones de reproducibilidad.

Frente a los trabajos previos que abordan la clasificación de texto en e-commerce, esta propuesta se diferencia en tres dimensiones. En primer lugar, incorporará modelos basados en LLM mediante API (OpenAI text-embedding-3-small), un enfoque que no estaba disponible en el momento de la competencia original (2019) y que representa el estado del arte en uso de modelos de lenguaje sin infraestructura propia. En segundo lugar, cubrirá los tres paradigmas centrales del NLP moderno —redes neuronales recurrentes, Transformers sin fine-tuning y Transformers con fine-tuning— sobre el mismo dataset y con las mismas métricas, permitiendo una comparación equitativa que la literatura existente raramente ofrece en español. En tercer lugar, contempla la validación de extrapolabilidad de resultados entre muestras de distinto tamaño, incluyendo una evaluación de los desafíos de reproducibilidad de soluciones anteriores, aspectos críticos para la toma de decisiones en entornos industriales.

Este trabajo aporta evidencia empírica y documentada sobre el comportamiento de distintos enfoques para resolver un problema de clasificación de texto en NLP, un área donde la comparación sistemática entre paradigmas sobre un mismo dataset real es escasa, especialmente en español. Los ensayos a realizar —con el mismo preprocesamiento y las mismas métricas de evaluación— permitirán contrastar cómo performan modelos de distintas generaciones frente a un problema concreto de alta complejidad: más de 1.500 categorías, variabilidad léxica y escala industrial. Los resultados obtenidos, junto con la documentación detallada de cada pipeline, hiperparámetros y dependencias de software, constituirán un aporte verificable y reproducible al campo, útil tanto para investigadores como para equipos de ciencia de datos que enfrenten problemas similares de clasificación en lenguaje natural. Comparado con surveys de NLP en español (Cañete et al., 2020; Zhao et al., 2023), este trabajo aporta evidencia empírica en un dominio específico en lugar de benchmarks genéricos, contribuyendo a un área donde la literatura en español es aún escasa.

6. Objetivo del trabajo

Objetivo general

Evaluar el rendimiento de enfoques de clasificación de texto —embeddings estáticos, aprendizaje profundo y modelos basados en Transformers— en el marco del Meli Challenge 2019, identificando los factores técnicos y metodológicos que explican las diferencias de rendimiento entre modelos de distinta generación y escala.

Objetivos específicos

1. Analizar las características y el alcance de los modelos de clasificación de texto utilizados en la práctica: embeddings estáticos, aprendizaje profundo y modelos basados en la arquitectura Transformer y LLM, en el contexto del procesamiento de lenguaje natural para e-commerce.
2. Implementar pipelines completos de clasificación de texto que incluyan preprocesamiento, tokenización, obtención de embeddings y clasificación, utilizando: embeddings OpenAI (text-embedding-3-small), el modelo pre-entrenado BETO con fine-tuning, embeddings FastText con red neuronal, y la replicación de la solución ganadora con LSTM/GRU.
3. Comparar las métricas de rendimiento (accuracy, F1-score) de los modelos implementados y de la solución ganadora, para identificar los factores técnicos y de datos que explican sus diferencias en el problema de categorización del Meli Challenge 2019.

7. Transferencia de los resultados obtenidos.

Los resultados de este trabajo tienen aplicaciones prácticas que trascienden el problema específico del Meli Challenge 2019. Los pipelines documentados e implementados son directamente transferibles a cualquier problema de clasificación de texto en español que opere sobre datos de lenguaje natural con alta variabilidad léxica: categorización de tickets de soporte, clasificación de reseñas de productos, etiquetado de noticias, o asignación de documentos legales a categorías de un repositorio.

Desde el punto de vista de la transferencia a industrias específicas, los resultados son de especial relevancia para el sector de e-commerce y retail, donde la categorización automática de productos es un problema operacional de alto impacto. Organizaciones que cuenten con catálogos de más de 1.000 categorías y volúmenes de datos del orden de los millones de registros encontrarán en este trabajo una referencia directamente aplicable (Kozareva, 2015).

8. Trabajos relacionados

Problema central: clasificación de texto en e-commerce

La propuesta de este trabajo contrasta con la solución ganadora del Meli Challenge 2019, que combina LSTM/GRU con embeddings FastText, en dos dimensiones principales. En primer lugar, incorpora paradigmas que no existían o no estaban disponibles en 2019: modelos Transformer con fine-tuning (BETO) y embeddings de LLM vía API (OpenAI text-embedding-3-small), lo que permite evaluar si los avances del campo desde entonces se traducen en mejoras concretas sobre este problema específico. Devlin et al. (2019) demostraron que el paradigma de pre-entrenamiento y fine-tuning supera a los enfoques basados en redes recurrentes en la mayoría de las tareas de comprensión del lenguaje, hipótesis que este trabajo pone a prueba en el dominio concreto de categorización de productos en español. En segundo lugar, complementa el enfoque recurrente original incorporando FastText combinado con una red neuronal densa —en lugar de LSTM/GRU— como punto de comparación dentro del mismo paradigma de embeddings de subpalabras, permitiendo aislar el impacto de la arquitectura recurrente respecto de la representación del texto.

Identificaron previamente el problema: categorización de productos en e-commerce

Kozareva (2015) identificó el problema de categorización automática de productos en e-commerce como un desafío de clasificación multiclase con características propias del dominio: la ausencia de recursos léxicos preexistentes que capturen marcas, modelos y abreviaturas técnicas obliga a construir representaciones directamente desde los datos, sin poder apoyarse en ontologías o diccionarios de propósito general. Este trabajo parte de ese diagnóstico e incorpora representaciones basadas en embeddings densos y modelos Transformer, que capturan relaciones semánticas que las representaciones léxicas tradicionales no pueden expresar, evaluando si esos avances resuelven las limitaciones identificadas por Kozareva en el mismo tipo de problema.

Problemas relacionados: clasificación multiclase de texto

Dos líneas de trabajo son especialmente relevantes como antecedentes. Por un lado, Cañete et al. (2020) desarrollaron BETO, el primer modelo BERT pre-entrenado exclusivamente en español, demostrando que el fine-tuning sobre un modelo monolingüe obtiene mejores resultados que los modelos BERT entrenados en corpus multilingües en la mayoría de las tareas de NLP en español. Este trabajo utiliza BETO como modelo central del benchmark, adoptando directamente esa metodología de pre-entrenamiento monolingüe y fine-tuning supervisado. Por otro lado, Nam et al. (2014) demostraron que redes neuronales simples equipadas con técnicas modernas de entrenamiento —ReLU, dropout y AdaGrad— con cross entropy como función de pérdida alcanzan o superan el estado del arte en clasificación multiclase de texto a gran escala. Este trabajo extiende esa línea incorporando paradigmas posteriores —embeddings contextuales y Transformers— evaluando su comportamiento en el dominio específico de categorización de productos de e-commerce en español.

Misma metodología: benchmarks comparativos de modelos de NLP

Los benchmarks comparativos de modelos de NLP han sido un área de investigación activa desde la introducción de GLUE (Wang et al., 2018), que evaluó sistemáticamente BERT y sus variantes en tareas diversas de comprensión del lenguaje estableciendo un protocolo de comparación sobre el mismo conjunto de datos y métricas. Zhao et al. (2023), en su survey

de LLM, proporcionan una síntesis actualizada del estado del arte en clasificación de texto, incluyendo el impacto de la escala del modelo y del volumen de datos de pre-entrenamiento. La metodología de este trabajo sigue ese enfoque de benchmarking sistemático, aplicándolo a un problema específico —categorización de productos de e-commerce en español— con modelos de distintas generaciones y paradigmas.

9. Metodología

El trabajo es de tipo experimental-comparativo. Se implementarán y evaluarán múltiples modelos de clasificación de texto sobre el mismo dataset y con las mismas métricas, lo que permitirá una comparación controlada entre enfoques. El diseño es cuantitativo, con énfasis en métricas de rendimiento predictivo.

Emplazamiento

El trabajo se realiza en el marco de la Maestría en Explotación de Datos y Gestión del Conocimiento. Los experimentos se ejecutarán en dos entornos computacionales según los requerimientos de cada modelo. Los modelos que demandan mayor capacidad de cómputo —como BETO con fine-tuning sobre el dataset completo— se ejecutarán en un entorno local con GPU NVIDIA RTX 3060 (12GB VRAM). Los modelos basados en embeddings de API (OpenAI text-embedding-3-small) se obtendrán mediante llamadas a servicios en la nube de OpenAI. Adicionalmente, se utilizará Google Colaboratory (Colab) como entorno de experimentación en la nube pública de Google, que provee acceso a recursos de cómputo GPU/TPU sin infraestructura propia, especialmente útil para prototipado y validación de pipelines. El repositorio del código es público: https://github.com/mari-fra/tp_final.

Dataset

Se utiliza el dataset público del Meli Challenge 2019 (Mercado Libre, 2019), disponible en Kaggle. El dataset completo en portugués y español contiene 20 millones de registros. El subconjunto en español comprende 10 millones de registros con dos columnas principales: título del producto (texto libre en español) y categoría (etiqueta de clase). El dataset presenta más de 1.500 categorías con distribución desbalanceada. Para los experimentos con la API de OpenAI (costo por token), se utilizarán muestras estratificadas de 1.000 y 10.000 registros, aplicando muestreo estratificado por categoría para asegurar que las clases más relevantes estén representadas proporcionalmente, dado el desbalance del dataset con más de 1.500 categorías; para los modelos entrenados localmente o en Colab (BETO, FastText), se realizarán ensayos con muestras más amplias.

Preprocesamiento y variables

Las variables de entrada son los títulos de productos (texto libre). La variable de salida es la categoría del producto (clasificación multiclase con más de 1.500 clases). El preprocesamiento incluye normalización de caracteres y manejo de valores numéricos —normalizados pero no eliminados, siguiendo la estrategia de la solución ganadora—. Una decisión central en el pipeline es la estrategia de tokenización, que varía según el modelo: los modelos basados en FastText utilizan n-gramas de caracteres, lo que permite representar términos no vistos mediante subunidades; los modelos Transformer (BETO, OpenAI) utilizan tokenización por subpalabras mediante BPE/WordPiece. Adicionalmente, se aplicará un filtrado de categorías con menos de 20 ejemplos para garantizar la estratificación del split train/validación/test.

Para representar un título completo como un único vector a partir de los embeddings de sus palabras constituyentes, se aplica *mean pooling*: el vector del título p se obtiene como el

promedio de los vectores de cada uno de sus M tokens, siguiendo la metodología de Kozareva (2015):

$$p = [e_1, \dots, e_a] \text{ donde } e_i = (1/M) \cdot \sum_{j=1}^M e_i w_j$$

(Ec. 1 — Mean Pooling) Fuente: Kozareva (2015), Sec. 4.1

donde d es la dimensión del vector de embedding, e_i es el valor en la posición i del vector del título, y $e_i w_j$ es el valor en la posición i del vector de la palabra w_j . Este enfoque es utilizado en los modelos basados en embeddings estáticos (FastText). Los modelos Transformer (BETO) utilizan el vector del token especial [CLS] como representación del título completo, mientras que la API de OpenAI devuelve directamente el vector agregado.

Modelos evaluados

Los modelos a implementar cubren los tres paradigmas descritos en el marco teórico. Para todos los modelos que incluyen una capa de clasificación neuronal, la función de salida es la función softmax, que transforma los logits de salida en una distribución de probabilidad sobre las K categorías posibles (Goodfellow, Bengio & Courville, 2016):

$$\hat{y}_k = \exp(z_k) / \sum_{j=1}^K \exp(z_j), \quad k = 1, \dots, K$$

(Ec. 2 — Función Softmax (clasificación multiclase)) Fuente: Goodfellow et al. (2016), Cap. 6

donde z_k es el logit de la clase k y K es el número total de categorías (más de 1.500 en el dataset del Meli Challenge 2019). La clase predicha es aquella con mayor probabilidad: $\hat{y} = \operatorname{argmax}_k \hat{y}_k$.

El entrenamiento de los modelos neuronales minimiza la función de pérdida de entropía cruzada (cross-entropy), que mide la discrepancia entre la distribución predicha y la distribución real de clases. Esta es la función de pérdida utilizada por BETO, FastText con red neuronal y la solución ganadora con LSTM/GRU, tal como documentan Nam et al. (2014) y Goodfellow et al. (2016):

$$L = -\sum_{k=1}^K y_k \cdot \log(\hat{y}_k)$$

(Ec. 3 — Función de pérdida: Cross-Entropy) Fuente: Goodfellow et al. (2016), Cap. 6; Nam et al. (2014)

donde y_k es 1 si la instancia pertenece a la clase k y 0 en caso contrario (one-hot encoding), y $\hat{y}_k$ es la probabilidad predicha para la clase k por la función softmax. La minimización de esta función mediante Descenso de Gradiente Estocástico (SGD) ajusta iterativamente los parámetros del modelo para mejorar la predicción sobre el conjunto de entrenamiento.

Los modelos específicos a implementar son:

- **Embeddings OpenAI (API)** con clasificadores KNN y Random Forest (muestra 1k y 10k estratificada).
- **BETO con fine-tuning.** Dos experimentos: muestra de 70k registros y dataset completo (~10M).
- **FastText con red neuronal densa** (dataset completo en español).

-
- **Solución Original:** Replicación (con workarounds documentados) de la solución ganadora del 2019 (LSTM/GRU + FastText).

Métricas de evaluación

La métrica principal de evaluación es la accuracy global, definida como la proporción de predicciones correctas sobre el total de predicciones realizadas:

$$Accuracy = (TP + TN) / (TP + TN + FP + FN)$$

(Ec. 4 — Accuracy) Fuente: Jurafsky & Martin (2024), Cap. 4

donde TP (True Positives) son los casos correctamente clasificados como positivos, TN (True Negatives) los correctamente clasificados como negativos, FP (False Positives) los incorrectamente clasificados como positivos, y FN (False Negatives) los incorrectamente clasificados como negativos. La comparación principal se realiza sobre accuracy global para comparabilidad con el score de 0.917 reportado en el leaderboard del Meli Challenge 2019. Cuando el experimento lo permite, se reportan también precision y recall por clase.

Limitaciones del estudio

La replicación de la solución ganadora no será exacta debido a incompatibilidades de dependencias (TensorFlow 1.14, CUDA 10.0). Los experimentos con API de OpenAI están limitados en tamaño de muestra por razones de costo. Los resultados son específicos del dominio de e-commerce en español y pueden no generalizarse directamente a otros dominios o idiomas.

10. Plan de Trabajo

La siguiente tabla resume las tareas principales del trabajo final con sus fechas estimadas de inicio y finalización.

Tarea	Descripción	Inicio	Fin
1. Revisión bibliográfica y marco teórico	Relevamiento de literatura, elaboración del marco teórico y del plan de trabajo	Enero 2026	Febrero 2026
2. Exploración y preprocesamiento del dataset	Análisis exploratorio del dataset del Meli Challenge 2019, normalización, tokenización y preparación de splits train/validación/test	Enero 2026	Febrero 2026
3. Implementación de modelos	Diseño e implementación de los pipelines de clasificación para cada enfoque: redes neuronales con FastText, Transformers sin fine-tuning (OpenAI embeddings) y Transformers con fine-tuning (BETO). Replicación de la solución ganadora del 2019 con documentación de workarounds	Febrero 2026	Abril 2026
4. Evaluación y análisis comparativo	Ejecución de experimentos, recopilación de métricas (accuracy, F1-score) y análisis comparativo entre modelos y paradigmas	Abril 2026	Mayo 2026
5. Redacción del informe final	Elaboración de las secciones de Resultados, Discusión, Conclusiones y Trabajo Futuro	Mayo 2026	Junio 2026

Referencias

- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. *Practical ML for Developing Countries Workshop, ICLR 2020*. <https://arxiv.org/abs/2308.02976>
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *Proceedings of EMNLP 2014*, 1724–1734. <https://arxiv.org/abs/1406.1078>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186. <https://arxiv.org/abs/1810.04805>
- García, E. (2019). *MeLi data challenge 2019 — winner solution* [repositorio GitHub]. <https://github.com/eduagarcia/meli-challenge-2019>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. <https://www.deeplearningbook.org>
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Jurafsky, D., & Martin, J. H. (2024). *Speech and language processing* (3rd ed., online draft). <https://web.stanford.edu/~jurafsky/slp3/>
- Kozareva, Z. (2015). Everyone likes shopping! Multi-class product categorization for e-commerce. *Human Language Technologies: The 2015 Annual Conference of the North American Chapter of the ACL*, 1329–1333. <https://aclanthology.org/N15-1147>
- Manning, C. D., & Schütze, H. (1999). *Foundations of statistical natural language processing*. MIT Press.
- Mercado Libre. (2019). *MeLi data challenge 2019* [Kaggle competition]. <https://www.kaggle.com/c/mercadolibre-data-challenge-2019>
- Nam, J., Kim, J., Loza Mencía, E., Gurevych, I., & Fürnkranz, J. (2014). Large-scale multi-label text classification — revisiting neural networks. *Proceedings of ECML PKDD 2014*, 437–452. https://doi.org/10.1007/978-3-662-44851-9_28
- Pineau, J., Vincent-Lamarre, P., Sinha, K., Larivière, V., Beygelzimer, A., d'Alché-Buc, F., Fox, E., & Larochelle, H. (2021). Improving reproducibility in machine learning research. *Journal of Machine Learning Research*, 22(1), 7459–7478. <https://jmlr.org/papers/v22/20-1364.html>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008. <https://arxiv.org/abs/1706.03762>

Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., & Bowman, S. R. (2018). GLUE: A multi-task benchmark and analysis platform for natural language understanding. *Proceedings of EMNLP 2018 Workshop BlackboxNLP*. <https://arxiv.org/abs/1804.07461>

Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., & Wen, J.-R. (2023). A survey of large language models. *arXiv preprint arXiv:2303.18223*. <https://arxiv.org/abs/2303.18223>